

O que danado é um *World Model*?

Uma Introdução às Representações Internas em Inteligência Artificial

Vitor N. Cabral de Oliveira

vnco@cin.ufpe.br

August 1, 2026

Roteiro

1. Introdução
2. Fundamentos Cognitivos
3. Dois Paradigmas: Preditivo vs Generativo
4. Fundações Teóricas de Schmidhuber
5. Arquiteturas Fundamentais
6. World Models Baseados em Transformers
7. Aplicações
8. Métricas de Avaliação
9. Problemas em Aberto
10. Conclusão

1


Introdução

O que é um *World Model*?

Definição

Um world model é uma representação interna que um agente constrói do seu ambiente, permitindo:

- _ **Prever** estados futuros do ambiente
- _ **Raciocinar** sobre consequências de ações
- _ **Planejar** sem tentativa-e-erro no mundo real



2

Fundamentos Cognitivos

Modelos Mentais na Psicologia

Kenneth Craik (1943) — *The Nature of Explanation*

- _ Organismos constroem “**modelos em miniatura**” da realidade
- _ Capacidade de antecipar eventos e testar alternativas mentalmente
- _ Precursor direto dos *world models* em IA

Correlato Neurológico: Vias Visuais

Via Ventral Reconhecimento de objetos (“*o quê*”)

Via Dorsal Processamento espacial (“*onde/como*”)

Arquiteturas modernas de *world models* frequentemente espelham esta separação.

Princípio da Energia Livre (FEP)

Karl Friston — Sistemas auto-organizáveis minimizam *energia livre variacional* para resistir à entropia.

Um agente mantém um modelo generativo $p(o_t, s_t)$ sobre observações o_t e estados latentes s_t :

$$F = \mathbb{E}_{q(s_t)} [\log q(s_t) - \log p(o_t, s_t)] = D_{\text{KL}}(q(s_t) \parallel p(s_t \mid o_t)) - \log p(o_t) \quad (1)$$

Percepção $\equiv$ inferência variacional: minimizar F maximiza a evidência do modelo interno.

Inferência Ativa

Ação e percepção como dois lados da mesma moeda:

- **Percepção**: atualiza crenças internas $q(s_t)$ para ajustar aos dados o_t
- **Ação**: altera o ambiente para forçar dados futuros a se conformarem às expectativas do modelo


Decomposição da Energia Livre Esperada $G(\pi)$:

$$G(\pi) \approx \sum_{\tau} \underbrace{-\mathbb{E}_{q(s_{\tau}|\pi)}[\mathcal{H}(q(o_{\tau} | s_{\tau}))]}_{\text{Epistêmico (Redução de Ambiguidade)}} + \underbrace{D_{\text{KL}}(q(o_{\tau} | \pi) \parallel p(o_{\tau}))}_{\text{Instrumental (Minimização de Risco)}} \quad (2)$$

Unifica estruturalmente o dilema exploração–exploração do RL *model-free*.

Codificação Preditiva

Rao & Ballard (1999) — O córtex cerebral implementa uma arquitetura hierárquica que otimiza energia livre via *predictive coding*.



- _ Predições *top-down* suprimem atividade em camadas inferiores
- _ Apenas erros residuais ε_t sobem na hierarquia
- _ Mapeia diretamente para RSSMs e PCNs modernos

3

Dois Paradigmas: Preditivo vs Generativo

Modela a dinâmica de transição: $p(s_{t+1} \mid s_t, a_t) = f_{\theta}(s_t, a_t)$

Propósito

Previsão: dado o que aconteceu, o que acontecerá?


Representantes:

- Ha & Schmidhuber (2018): VAE + RNN — arquitetura original *World Models*
- LeCun (JEPA): predição em espaço latente, não em pixels
- Dreamer (Hafner et al.): RSSM + *actor-critic* em trajetórias imaginadas

LeCun (2022) — Estrutura de *self-supervised learning* que prevê em espaço latente:

$$\hat{s}_y = \text{Predictor}(s_x, \theta), \quad \mathcal{L} = \|\hat{s}_y - s_y\|^2 \quad (3)$$

- **Prevenção de colapso:** *stop-gradient* no encoder alvo
- **Abstração:** descarta detalhes imprevisíveis (ruído de pixel), captura estrutura semântica
- **Jerarquia:** módulos JEPA empilhados operam em diferentes escalas temporais



Paradigma Generativo

Modela a distribuição conjunta completa:

$$p(o_1, \dots, o_T, a_1, \dots, a_T) = \prod_{t=1}^T p(o_t, a_t \mid o_{<t}, a_{<t}) \quad (4)$$

Representantes:

- **Google Genie**: tokenizador de vídeo + modelo de dinâmica causal; mundo jogável a partir de uma única imagem
- **GAIA-1 / UniSim**: transformers de vídeo em larga escala que aprendem física intuitiva diretamente de pixels

Avaliação

Qualidade da amostra, diversidade distribucional, consistência temporal de longo horizonte

Paradigmas em Contraste

Dimensão	Preditivo	Generativo
Objetivo Primário	Minimizar distância latente	Maximizar log-verossimilhança
Tipo de Saída	Predição de estado abstrato	Amostragem do fluxo observacional
Sinal de Aprendizagem	Alinhamento de atributos	Reconstrução / <i>token loss</i>
Utilidade	Planejamento <i>local look-ahead</i>	Simulação ambiental
Vulnerabilidade	Colapso representacional	Alto custo amostral

Paradigmas em Contraste

Dimensão	Preditivo	Generativo
Objetivo Primário	Minimizar distância latente	Maximizar log-verossimilhança
Tipo de Saída	Predição de estado abstrato	Amostragem do fluxo observacional
Sinal de Aprendizagem	Alinhamento de atributos	Reconstrução / <i>token loss</i>
Utilidade	Planejamento <i>local look-ahead</i>	Simulação ambiental
Vulnerabilidade	Colapso representacional	Alto custo amostral

A fronteira é fluida — Dreamer usa um modelo generativo para *rollouts* preditivos; Genie integra um controlador preditivo em um pipeline generativo.

4

Fundações Teóricas de Schmidhuber

Curiosidade Artificial (1991)

Recompensa intrínseca por erros de predição aprendíveis:

$$\text{curiosity reward} = \|\hat{s}_{t+1} - s_{t+1}\|^2 \quad (\text{apenas se aprendizável}) \quad (5)$$

Inspirou módulos de curiosidade intrínseca em RL moderno (ICM, Pathak et al. 2017).


Teoria Formal da Criatividade (2012)

- “Beleza” $\propto$ progresso de compressão/aprendizagem no *world model* do observador
- Obras de arte, ciência e humor geram progresso de compressão aprendizável

5

Arquiteturas Fundamentais

Ha & Schmidhuber (2018): Arquitetura VMC



1. **Visão (V)**: VAE comprime observações x_t em latente $z_t \sim \mathcal{N}(\mu_t, \sigma_t)$
2. **Memória (M)**: RNN prediz próximo estado latente $\hat{z}_{t+1} = f_\theta(z_t, a_t)$
3. **Controlador (C)**: Política $a_t = \pi(z_t)$ treinada no espaço latente

Planejamento por “*sonhar*” — *rollouts* no espaço latente sem simulação em nível de pixel.

RSSM — *Recurrent State-Space Model*

Hafner et al. (Dreamer) — Combina estados determinísticos e estocásticos:

$$h_t = f_\phi(h_{t-1}, z_{t-1}, a_{t-1}) \quad (\text{determinístico}) \quad (6)$$

$$z_t \sim \mathcal{N}(\mu_\phi(h_t), \sigma_\phi(h_t)) \quad (\text{estocástico}) \quad (7)$$

$$\hat{o}_t = g_\phi(h_t, z_t) \quad (\text{reconstrução}) \quad (8)$$

- h_t carrega dependências temporais de longo alcance
- z_t captura futuros multimodais
- Evita colapso posterior de modelos puramente estocásticos

DreamerV2 e V3

DreamerV2 (Hafner et al., 2021)

- Latentes **discretos** (categóricos) ao invés de Gaussianos
- **KL balancing**: coeficientes separados para *prior* e *posterior*
- Predição de recompensa *two-hot*

$$z_t = \text{one-hot}(\underset{k}{\operatorname{argmax}} \pi_k) + \pi - \text{sg}(\pi) \quad (9)$$

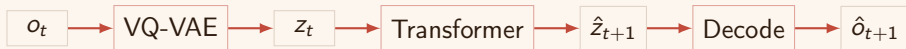
DreamerV3 (Hafner et al., 2023)

- Hiperparâmetros únicos para centenas de ambientes
- **Predições Symlog**:
 $\text{symlog}(x) = \text{sign}(x) \log(|x| + 1)$
- **Free bits**: regularizador KL que evita colapso
- Predições normalizadas por estatísticas correntes

6

World Models Baseados em Transformers

Micheli et al. (2023) — Substitui memória recorrente por transformers:



$$p(z_{t+1} \mid z_{\leq t}, a_{\leq t}) = \prod_{k=1}^K p(z_{t+1}^k \mid z_{\leq t+1}^k, z_{\leq t}, a_{\leq t}) \quad (10)$$

- Observação o_t tokenizada por VQ-VAE em códigos discretos z_t
- Transformer autoregressivo prediz a próxima sequência de tokens
- Eficiência amostral competitiva com métodos *model-free*

7

Aplicações

Aplicações de *World Models*

Robótica

- *DayDreamer*:
DreamerV3 em robôs reais
- Políticas treinadas na “imaginação”
- Mínima interação com o mundo físico

Direção Autônoma

- Wayve: simulação de direção
- Avaliação *closed-loop* de políticas
- Segurança: teste de cenários críticos sem risco real

RL Baseado em Modelo

- *Rollouts* alucinados
- Eficiência amostral: ordens de grandeza
- Planejamento ciente de incerteza (ensembles)

8

Métricas de Avaliação

Métricas de Avaliação

Métrica	Descrição
Prediction MSE	Erro quadrático médio em nível de pixel ou latente
Divergência KL	Casamento entre <i>prior</i> e <i>posterior</i> latentes
Acurácia de Planejamento	Correlação entre trajetórias imaginadas e retornos reais
Eficiência Amostral	Passos de ambiente necessários para atingir <i>threshold</i> de recompensa
Gap de Generalização	Queda de performance em variações não vistas do ambiente

9

Problemas em Aberto


Problemas em Aberto

- Composicionalidade** Como construir *world models* que combinam conceitos conhecidos para generalizar a cenários novos?
- Predição de Longo Horizonte** Erros de predição se acumulam quadraticamente — difusão iterativa, atenção esparsa e separação hierárquica de escalas são soluções exploradas.
- Escalabilidade** Ambientes controlados (ViZDoom, CarRacing) → mundo real aberto com observações de alta dimensão.
 - Grounding** Como manter significado consistente das representações latentes entre diferentes tarefas?
- Causalidade** Distinguir intervenção de observação para raciocínio contrafactual genuíno.

10

Conclusão

Trajetória



- *World models* representam a convergência de ciência cognitiva, teoria de controle e *deep learning*
- Desafios-chave: composicionalidade, longo horizonte, escalabilidade, causalidade
- Papel central na próxima geração de sistemas inteligentes